


兩個模型，走同一條考場

只更換模型；題目、提示、電腦與評分方式保持相同。



這次沒有測什麼？

兩邊都沒有掛人格微調，所以這不是『誰更像目標人物』的測試，也不是完整聊天系統總分。

Qwen3.5 更容易把左腦重點完整說出來

主要優勢是『少漏重點』，不是每一句都自然。

三個候選中，至少一個完整

Qwen2.5



Qwen3.5



119/144 組

143/144 組

99.3% 要怎麼看？

每題重跑 3 次；每次產生 3 句。只要其中 1 句把所有必要重點說出來，該組就算成功。

不是每一句都有 99.3 分。

單句完整率

Qwen2.5

51.2%

Qwen3.5

84.5%

必要重點命中

Qwen2.5

76.8%

Qwen3.5

93.7%

嚴重文字問題（越低越好）

Qwen2.5

51.2%

Qwen3.5

22.7%

同一題的重點差異：『截止日不是星期五，是星期四』

Qwen2.5：金曜日じゃなくて木曜日だよ。

只說星期四，漏掉『截止』與『接受訂正』

Qwen3.5：締切は木曜だったね。訂正して言い直すよ。

三個重點都有說出來

Qwen3.5 不是不會動，而是太容易亂動

需要的動作大多抓得到；真正弱點是『不該動時停不下來』。

工具完全正確

Qwen2.5

68.3%

Qwen3.5

51.7%

需要動作時有抓到

Qwen2.5

95.3%

Qwen3.5

96.7%

不該動時真的沒動

Qwen2.5

54.3%

Qwen3.5

24.3%

造成分數下降的主因

多做或做錯動作：Qwen2.5 37/120

Qwen3.5 57/120

幾乎每兩題就有一題多做動作

普通聊天

「最近有好玩的遊戲嗎？」

應該不動



卻切成驚訝表情

意思不清楚

「好像想要你指，又好像不想。」

應該先不動



卻執行指向動作

否定命令

「不要指。」

應該不動



卻真的執行指向

Qwen3.5 在這台 Mac 上約慢 4 倍

模型較大、每句更長，而且提示文字的處理也比較慢。

每次回答的中間速度



Qwen2.5



1.10 秒

Qwen3.5



4.47 秒

約 4.05 倍

但仍低於 5 秒上限

模型大小 (B=十億)

7.6B

Qwen2.5

9.7B

Qwen3.5

參數更多

模型輸出單位

22

Qwen2.5

38

Qwen3.5

Qwen3.5 多約 73%

提示處理

0.04 秒

Qwen2.5

2.34 秒

Qwen3.5

目前最大的時間差

回答生成

0.87 秒

Qwen2.5


1.88 秒

Qwen3.5

單次生成也較慢

不整體替換；把語言與動作分開處理

這次結果支持『分工』，不支持直接把 Qwen3.5 全面上線。



這次結果不能證明

Qwen3.5 更像目標人物、完整聊天系統已提升，或系統已具有人類心智。它只回答『哪個本機模型適合哪一種工作』。