

技術進捗レポート：右脳と GitHub 化

前回報告後の主な問題は、左脳がまったく考えられないことではなく、右脳の最終出力が不安定なことだった。左脳が伝えたい要点が抜ける、不要な文字が混ざる、自然に見えても契約に合わない返答になる可能性があった。



改造前

0%

実モデル候補は左脳の意味を残しにくい。

安全出力

100%

失敗時も fallback が契約を守る。

今回の判定

切替なし

V8 は gate 未通過。既定モデルにしない。

一文まとめ：今回は右脳が完成したという主張ではなく、「実モデルをいつ本番に出してよいか」を測定遮断追跡できる形にした。

右脳契約整合：何を変えたか




変更点	目的	プロジェクト上の意味
契約 version v1	runtime payload と訓練データの欄位を同じ形式にする。	訓練時は A 形式、実行時は B 形式というズレを減らす。
元の中国語入力を隠す	モデルには左脳が整理した日本語 meaning だけを見せる。	右脳がユーザーの中国語を直接まねたり、日本語応答へ混ぜたりするのを防ぐ。
厳格な候補 gate	意味スロット、ASCII 漏れ、中国語混入、過剰介入を検査する。	間違った候補が最終チャット出力に入らないようにする。
base-only 対照	LoRA なしの基準状態も測れるようにする。	改善が単に base model の能力だけではないか確認できる。

一文まとめ：今回補強したのは右脳の実出力契約であり、ToMBench の問題を小テスト対策として覚えさせたわけではない。

現在の数値：何を主張できるか

小型開発セット結果



データセット

1025

旧 curriculum を訓練用へ
転用。

訓練分割

train 943 / eval 82。

Eval loss

3.35

数値低下は本番化の証明
ではない。

採用判定

No

行動 gate 未通過。

現在主張できること：GitHub フローは確立した。右脳を本番投入する前の安全門と契約はできた。V8 は価値のある実験だが、まだ本番基準ではない。

現在主張できないこと：右脳が正式に自然化した、安定接管できる、または今回の F 改造だけで ToMBench 点数が直接上がる、とはまだ言えない。