

工程進度報告：右腦與 GitHub 化

上次報告後，主要問題不是左腦完全不會想，而是右腦最後輸出不穩：可能漏掉左腦要表達的重點、混入不該出現的字、或產生看似自然但不符合契約的回覆。



改造前

0%

真實模型候選會產生，但很難穩定保留左腦語意。

安全輸出

100%

候選失敗時，fallback 仍能保持最終回覆契約。


本次判定

不切換

V8 訓練有損失下降，但行為門檻未通過，所以不切換預設。

一句話：這次不是宣稱右腦已經變強，而是把『真實模型何時可以上線』變成可測、可擋、可追蹤。

右腦契約對齊：改了哪裡




改動	目的	對整體專案的意義
契約版本 v1	讓 runtime payload 和訓練資料使用同一種欄位。	降低『訓練時看的是 A 格式，上線時收到 B 格式』的錯位。
隱藏原始中文輸入	模型只看左腦整理後的日文 meaning。	避免右腦直接學使用者中文或把中文混進日文回覆。
嚴格候選 gate	檢查語意槽、ASCII 泄漏、中文混入、過度介入。	讓錯誤候選不能進入最終聊天輸出。
base-only 對照	可以測沒有 LoRA 時的基準。	確認改善不是單純 base model 自己會。

一句話：這次真正補的是右腦的輸出契約，不是把 ToMBench 題目塞給模型當小抄。

目前數據：能主張什麼

小型開發集結果



資料集

1025

從舊 curriculum 轉成正式訓練資料；不能再當 hold out。

訓練切分

train 943 / eval 82。

Eval loss

3.35

V8 訓練後有數值下降，但這不等於聊天可上線。

採用判定

No

行為 gate 未通過，所以不切預設。

目前可以主張：GitHub 流程已建立；右腦上線前的安全門與契約已建立；V8 是一次有價值但未達上線門檻的實驗。

目前不能主張：右腦已經正式自然化、已經能穩定接管、或 ToMBench 分數會因這次 F 改造而直接上升。