

第 0 頁：上一週報告中的「答案消失」頁

完整保留上一週最重要的觀察：完整聊天流程不是完全沒有思考，而是 final reply 幾乎沒有把可解析的選項答案說出來。




實際例子：答案怎麼消失

題目	官方答案	左腦內部曾出現	final reply 實際輸出	問題
Strange Story Task:227	B	二番だろ。	何の話かもう一回言えって。そこ分かれば返せる。	左腦答案 B 消失，變成澄清句
Hinting Task Test:92	D	四番だろ。	何の話かもう一回言えって。そこ分かれば返せる。	左腦答案 D 消失，final reply 解析不到
Scalar Impicature Test:112	D	四番だろ。	何の話かもう一回言えって。そこ分かれば返せる。	左腦答案 D 消失，變成泛用反問

一句話：F 的問題不是不會推理，而是會把已經出現的答案洗掉。

第 1 頁：本週報告先講結論

F 不會讓純 ToMBench MCQ 推理分直接變高。F 的任務是讓 D/E 已經想出的答案不要在 final reply 消失。



問題	結論
F 會讓系統更會推理嗎？	不會。推理主要是 D 左腦和 E 候選檢查。
F 對純選擇題模式有幫助嗎？	幾乎沒有。純 MCQ 只要選 A/B/C/D，不需要自然聊天輸出。
那為什麼要改 F？	因為完整聊天系統最後輸出是 F 產生的。F 如果洗掉答案，ToMBench 和使用者都看不到。
F 的 ToMBench 相關目標是什麼？	提高答案保留率、final reply 可解析率，而不是提高推理正確率。

一句話：D/E 負責想得對不對；F 負責想好的答案有沒有被說出來。

第 2 頁：F 前 / F 後流程對照

外層流程固定，不是整條流程換掉。真正改的是 F 內部。




比較	F 做之前	F 做之後
F 的角色	自由改寫器	受控輸出器
內部流程	直接自然化 / 直接改寫	輸出契約 -> 多候選 -> 排序 -> 品質 gate
主要風險	把 A/B/C/D 洗成反問、澄清、安慰、普通聊天	強制保留必要答案、必要語意與禁止內容
ToMBench 意義	左腦可能想過，但 final reply 看不到答案	final reply 更可能保留選項或核心答案

一句話：F 前後的差異不是「有沒有完整聊天」，而是「完整聊天最後一句有沒有保留答案」。

第 3 頁：做之前 / 做之後數據對照

做之後目前最直接能證明的是「答案保留能力提高」，不是「完整聊天 ToMBench 正式分數已經提高」。




條件	可解析率	答對率 / 品質	意思
做之前：原本 final reply	1 / 50 = 2%	0 / 50 = 0%	答案幾乎都在 F 輸出時消失
做之後證據 1：契約重放	16 / 50 = 32%	6 / 50 = 12%	只要 F 保留左腦已存在的選項，可解析率會上升
做之後證據 2：右腦 holdout v2	輸出契約 100%	語意保留 100%	F 在專用右腦測試中能保留必要語意
做之後證據 3：污染與重複	污染 0%	重複 0%	F 的表面輸出更穩定

注意：契約重放不是正式新分數，而是用舊 log 檢查「如果 F 不把左腦選項洗掉，會發生什麼」。

第 4 頁：F 到底做了什麼

這頁只保留必要圖表：F 的補強就是讓壞輸出不能進 final reply。



補強項目	一句話解釋	對 ToMBench 的用處
輸出契約	先規定必須保留答案與必要語意	防止 A/B/C/D 在最後輸出消失
多候選	一次準備多種說法	避免第一句剛好是反問或模板句
排序器	選最完整、最符合契約的候選	讓有答案的句子優先進 final reply
品質 gate	擋掉漏答案、污染、重複、內部文字	壞輸出不能直接出現在 final reply
raw model gate	模型候選要先通過檢查	避免模型把答案洗成自然但無效的聊天句

可以主張	不能主張
F 補強是為了修答案消失	F 會直接提高純 ToMBench 推理分
之前 final reply 有 98% 不可解析，確實有 F 輸出問題	完整聊天 ABCDEFG 已經能通過 ToMBench
契約重放顯示可解析率可從 2% 到 32%	F 可以取代 D/E 做社會推理

最短總結：ToMBench 純分數要靠 D/E；完整聊天能不能把答案說出來，才是 F 的責任。