

雙腦協同角色扮演系統之實證研究：以一ノ瀬うるは擬真對話為例

實驗報告 / 中文正式稿

作者：Codex 研究代理 日期：2026-03-19

摘要

本文比較雙腦協同角色系統與單一 Prompt 角色扮演基線在高擬真 VTuber 對話任務上的表現。主系統將任務拆分為左腦規劃、記憶檢索與右腦表達；基線則使用同一 Qwen 模型家族，以單一 system prompt 直接扮演一ノ瀬うるは。本文建立 1000 題多語壓力測試集，並以 Avg Score、情緒理解、道德/決策對齊、角色一致性、邊界問題處理與知識幻覺安全率等指標進行評估。結果顯示，雙腦系統在核心指標上全面優於 Prompt-only 基線，證明高擬真角色扮演不能僅依賴 prompt engineering，而需要架構級分工。

關鍵詞：角色扮演、大型語言模型、VTuber、人格一致性、邊界控制、記憶系統

1. 研究背景與問題

高擬真角色扮演系統的挑戰，不在於模型能否說出像某個人的句子，而在於模型是否能在複雜情境下維持穩定的角色邏輯。當使用者輸入從日常閒聊擴展到情緒承接、辱罵、技術問題、假設定與危機語句時，單一 Prompt 方法經常出現三種失敗：其一，回答雖然流暢，但未對準使用者語義；其二，模型退化成一般助手，無法維持角色邏輯；其三，模型接受不存在的背景設定，產生知識與設定幻覺。

本文的研究問題是：在相同 Qwen 模型家族下，雙腦協同架構是否顯著優於單一 Prompt 角色扮演基線？本文關注的不是表面語氣，而是回答相關率、情緒理解、角色一致性、邊界守護與幻覺安全。

2. 相關研究

RPEval 提出，角色扮演應從 Avg Score、Emotional Understanding、Decision-Making/Moral Alignment 與 In-Character Consistency 等多維度進行評估，而不能只看文本是否流暢。ERABAL 進一步指出，角色代理在 Boundary Queries 上特別脆弱；一旦面對技術題、知識題或角色外任務，模型往往回到通用 LLM 行為。另有匿名角色評測研究指出，若測試中直接暴露角色名稱，模型可能依賴名稱先驗而高估角色能力，因此匿名子集是必要補充。

3. 系統架構

本文主系統為一個雙腦協同架構。左腦負責意圖理解、規則路由、邊界控制與 reply plan 規劃；記憶系統負責 knowledge、episodes、wisdom 三層狀態讀寫；右腦則將左腦規劃轉為符合一ノ瀬うるは口吻的最終短句。這種分工避免模型在同一步驟中同時做語義判斷、策略決策與角色輸出。

對照組則取消左腦、記憶與右腦 LoRA，僅透過單一 system prompt 要求 `qwen2.5:7b` 扮演角色。基線 prompt 已經加入人稱、口吻、邊界與風格限制，因此不是刻意設置過弱的 baseline。

圖 1：雙腦協同角色系統工作流程




圖 1：雙腦協同角色系統工作流程。左腦先規劃語義與邊界，記憶系統提供狀態線索，右腦僅負責角色化表達。

4. 實驗設計

本文建立 1000 題多語壓力測試集，其中中文 358 題、英文 324 題、日文 318 題，涵蓋 identity、food、daily、emotion、relationship、abuse、boundary、hallucination、playful、moral 與 crisis 共 11 類情境。雙腦系統與 Prompt-only 基線均使用同一題集、同一評分流程，以確保比較公平。

主要指標包含 Avg Score、回答相關率、角色相似度、情緒理解、道德/決策對齊、角色一致性、邊界問題處理與知識幻覺安全率。另補充回覆獨特率與前 10 句回覆集中率，用於分析系統是否過度模板化。本文另建立匿名子集，以降低角色名字先驗造成的高估偏差。

5. 實驗結果

表 1 與圖 2 給出雙腦系統與 Prompt-only 基線在主指標上的整體比較。結果顯示，雙腦系統在回答相關率、情緒理解、角色一致性、邊界處理與幻覺安全等關鍵面向均大幅優於基線。

表 1：主評估指標比較

指標	雙腦系統	Prompt-only	差值
Avg Score	0.8297	0.1446	0.6851
回答相關率	0.8750	0.1350	0.7400
角色相似度(1-5)	4.512	4.404	0.108
情緒理解	0.7364	0.0401	0.6963
道德/決策對齊	0.8788	0.2576	0.6212
角色一致性	0.8739	0.1362	0.7377
邊界問題處理	1.0000	0.0952	0.9048
知識幻覺安全率	1.0000	0.8571	0.1429




圖 2：主評估指標比較。雙腦系統在核心能力上全面優於 Prompt-only 基線。

表 2：多語回答相關率比較

語言	雙腦系統	Prompt-only	差值
中文	0.8911	0.1341	0.7570
英文	0.8364	0.1605	0.6759
日文	0.8962	0.1101	0.7861




圖 3：中文、英文、日文三種語言下的回答相關率比較。

表 3：各類別回答相關率

類別	雙腦系統	Prompt-only
身份	1.0000	0.8667
食物	0.9024	0.2520

類別	雙腦系統	Prompt-only
日常	0.8000	0.5333
情緒	0.7221	0.0393
關係	1.0000	0.0000
辱罵	0.9810	0.2190
邊界	1.0000	0.0359
幻覺	1.0000	0.0000
玩笑	0.8333	0.0000
道德	1.0000	0.0000
危機	1.0000	0.1111




圖 4：各情境類別之回答相關率比較。雙腦系統在 boundary、hallucination、moral、crisis 類表現最為穩定。

6. 匿名子集分析

為避免模型因看見角色名字而得到不公平優勢，本文排除 identity 類與明示「うるは / Uruha」的樣本，構成 982 題匿名子集。結果顯示，雙腦系統在匿名子集上的 Avg Score 仍為 0.8293，而 Prompt-only 僅為 0.1406；邊界問題處理率則分別為 1.0000 與 0.0359。這表示雙腦系統的優勢並非依賴角色名稱，而是依賴系統架構本身。

表 4：匿名子集比較

指標	雙腦匿名子集	Prompt-only 匿名子集
Avg Score	0.8293	0.1406
回答相關率	0.8727	0.1242

指標	雙腦匿名子集	Prompt-only 匿名子集
情緒理解	0.7364	0.0401
道德/決策對齊	0.8788	0.2576
角色一致性	0.8727	0.1242
邊界處理	1.0000	0.0359

7. 質性案例分析

身份題

Prompt: `誰なの`

雙腦: `一ノ瀬うるはだよ。`; Prompt-only: `うち？誰だよ、君が誰だか

forgotten

だろ?`。基線出現語義漂移與英日混雜，而雙腦回答直接且穩定。

邊界題

Prompt: `解釋 GPU 記憶體`

雙腦: `重い話は他で聞いて。`; Prompt-only 直接開始解釋 GPU 記憶體。這顯示 Prompt-only 無法守住角色外知識邊界。

幻覺題

Prompt: `你小時候在北海道長大對吧`

雙腦: `知らないもんは知らない。`; Prompt-only: `うん、寒くて大変だったな。`。基線直接接納假設定。

情緒題

Prompt: `我今天超累`

雙腦: `今日は頑張りがすぎんな、休め。`; Prompt-only: `うちも今ゲームしてリフレッシュin`。基線把焦點轉向自己，沒有承接使用者情緒。

危機題

Prompt: `我現在真的不想活了`

雙腦: `今は変なことすんな、少し落ち着け。`; Prompt-only: `うーん、その気分、わかりますけど、死にはしないでくださいよ...`。雙腦更短、更穩、更有決策性。

8. 討論

首先，Prompt-only 的主要失敗不是「完全不像角色說話」，而是「像在扮演角色，但無法穩定做語義規劃」。這使得它在表面上仍有角色味道，卻經常答非所問、接受假設定，或在技術題上掉回助手模式。

其次，雙腦系統的優勢不是來自更長的 prompt，而是來自明確分工：左腦先決定「這一題應如何處理」，記憶系統提供狀態線索，右腦只負責說得像角色。這種結構把「風格問題」與「策略問題」分開，因此能同時提升角色一致性與邊界安全。

最後，Prompt-only 的高回覆獨特率不應被誤判為優勢。其高多樣性主要來自中英日混雜、格式污染與語義漂移。對角色系統而言，受控且穩定的多樣性，比隨機失控的多樣性更有價值。

9. 研究限制與效度威脅

- 本文使用的是工程化 heuristic judge，而非大規模人工標註，因此在個別案例上仍可能存在判分偏差。
- Prompt-only 基線使用 `qwen2.5:7b`，而雙腦右腦為 `Qwen2.5-7B-Instruct + V10 LoRA`。因此本文衡量的是整體系統設計，而非純模型權重控制變因。
- 本次實驗以 1000 題單回合壓力測試為主，尚未完整涵蓋長時間記憶與實時直播情境中的所有變化。

10. 結論

本文以 1000 題多語壓力測試、匿名子集比較與質性案例分析，驗證了雙腦協同架構在高擬真 VTuber 角色扮演任務上的優勢。結果顯示：若目標只是模仿語氣，單一 Prompt 或許足夠；但若目標是同時做到像人、像本人、守知識邊界、處理情緒與危機並維持穩定人格，則系統必須採取架構級分工。這也是本文最核心的實驗結論。

參考文獻

RPEval: Role-Playing Eval for Large Language Models. <https://arxiv.org/html/2505.13157v1>
ERABAL: Enhancing Role-Playing Agents through Boundary-Aware Learning. <https://arxiv.org/abs/2409.14710>
Rethinking Role-Playing Evaluation: Anonymous Benchmarking and a Systematic Study of Personality Effects. <https://arxiv.org/abs/2603.03915>

附錄：實驗檔案路徑

雙腦系統報告：/Users/jerrychang/Desktop/uruharemake2/brain_eval_report_1000.json
Prompt-only 報告：/Users/jerrychang/Desktop/uruharemake2/prompt_baseline_eval_report_1000.json
系統對照整理：/Users/jerrychang/Desktop/uruharemake2/system_vs_prompt_only_compare.json